

Raport Analiza HLS-CMDS


Karol Piotrowski, Franciszek Cieśliński, Maciej Adamczyk

Temat: Klasyfikacja schorzeń serca oraz płuc na podstawie nagrań dźwiękowych ze stetoskopu.

Dane wejściowe: pliki .wav ze zbioru <https://archive.ics.uci.edu/dataset/1202/hls-cmds:+heart+and+lung+sounds+dataset+recorded+from+a+cl...>

Analiza Eksploracyjna

Liczebność klas:



Podzieliliśmy tak klasy, żeby mieć jak najwięcej danych w zbiorze trenującym, jednocześnie mając wystarczając danych w zbiorze testującym, aby dostosować parametry modelu


Ze względu na naturę analizy (osobne wykrywanie patologii serca i płuc), skrypt przetwarzający dane (separate.py) traktuje każdy wiersz jako źródło dwóch niezależnych próbek:

Sygnal serca: Wyodrębniany na podstawie kolumny Heart Sound Type

Sygnal płuc: Wyodrębniany na podstawie kolumny Lung Sound Type.

Szczegółowy balans klas (na podstawie 290 próbek): Analiza etykiet wykazuje znaczną przewagę próbek patologicznych

- **Całkowita liczba próbek:** 290
- **Klasa "Patologia":** 249 próbek (**85,9%**)
- **Klasa "Zdrowy" (Normal):** 41 próbek (**14,1%**)



Charakterystyka techniczna materiału

Zbiór danych składa się z 15-sekundowych nagrań audio w formacie **.wav**, próbkowanych z częstotliwością **22,050 Hz**. Nagrania rejestrują sygnały akustyczne serca, płuc lub mieszane dźwięki sercowo-płucne.

Nazewnictwo plików

Nazwy plików audio pełnią funkcję identyfikatorów (Sound ID) i zawierają zakodowane zmienne kategoryczne według schematu: [Płeć]_[Typ dźwięku]_[Lokalizacja].wav

Utworzenie potrzebnych plików csv

Dane wejściowe pochodziły z trzech niezależnych plików źródłowych: **HS.csv** (Heart Sounds), **LS.csv** (Lung Sounds) oraz **Mix.csv** (nagrania mieszane). W pierwszej fazie

dokonano unifikacji formatu danych oraz **binaryzacji etykiet diagnostycznych**. Złożone opisy schorzeń (np. "Wheeze", "Murmur", "Crackles") zostały zmapowane do dwóch klas głównych wymaganych przez model klasyfikacyjny:

- **Normal:** dla opisów "Normal".
- **Pathology:** dla wszystkich pozostałych stanów chorobowych.

Zunifikowany zbiór danych został poddany losowemu przetasowaniu (*random shuffle* z ziarnem 42 dla zapewnienia powtarzalności), a następnie podzielony na trzy rozłączne podzbiory w proporcjach:

- **Zbiór Treningowy (70%):** Służący do optymalizacji wag modelu.
- **Zbiór Walidacyjny (10%):** Wykorzystywany do monitorowania procesu uczenia i doboru hiperparametrów (np. k w k -NN).
- **Zbiór Testowy (20%):** Przeznaczony do ostatecznej ewaluacji skuteczności modeli na nieznanymi danych.

W celu umożliwienia głębszej analizy błędów (*Error Analysis*) w późniejszym etapie, "częściowe" pliki CSV (zawierające jedynie ścieżki i etykiety binarne) zostały ponownie skorelowane z oryginalnymi plikami źródłowymi. Zaimplementowano algorytm adnotujący (`annotate_df`), który na podstawie identyfikatorów nagrań (*Sound ID*) uzupełnił zbiory treningowe, walidacyjne i testowe o kluczowe zmienne kliniczne:

- **Szczegółowy typ dźwięku:** (np. Aortic Stenosis, Rhonchi) – pozwala sprawdzić, które patologie są najtrudniejsze do wykrycia.
- **Lokalizacja osłuchiwania (Body Location):** (np. Mitral, Tracheal) – pozwala ocenić wpływ punktu przyłożenia stetoskopu na jakość klasyfikacji.
- **Płeć pacjenta (Gender):** Umożliwia weryfikację ewentualnego biasu modelu względem płci.

Segmentacja Sygnału i Strategia Oversamplingu

Ze względu na różną długość nagrań źródłowych oraz znaczną przewagę liczebną klasy "Patologia" (ok. 85%) nad "Normal", zastosowano algorytm inteligentnej segmentacji. Każde nagranie zostało podzielone na okna czasowe o stałej długości **2 sekund** (co odpowiada ok. 2-3 cyklom pracy serca lub jednemu cyklowi oddechowemu).

W celu zbalansowania zbioru danych (rozwiązanie problemu *Class Imbalance*) zastosowano zmienny krok przesunięcia okna (*stride*):

- **Klasa "Patologia" (Dominująca):** Przesunięcie okna wynosi **2.0 s** (brak nakładania się segmentów).

- **Klasa "Normal" (Mniejszościowa):** Przesunięcie okna wynosi **0.5 s** (75% nakładania się segmentów).

Dzięki temu zabiegowi, z jednego nagrania osoby zdrowej generowane są 4-krotnie więcej próbek niż z nagrania patologicznego o tej samej długości. Pozwoliło to na sztuczne zwiększenie liczebności klasy mniejszościowej (*augmentacja*) bez wprowadzania syntetycznych danych. Skrypt automatycznie inferuje również modalność (modality: HS/LS) na podstawie metadanych.

Filtracja i Parametryzacja (MFCC)

Dla modeli klasycznych (k-NN) surowy sygnał audio został przetransformowany do postaci wektora cech numerycznych. Proces ten składał się z następujących kroków:

1. **Filtracja Pasmowoprzepustowa:** Zastosowano cyfrowy filtr **Butterwortha 4. rzędu** o paśmie przepustowym **100 Hz – 1500 Hz**. Celem było usunięcie szumów niskoczęstotliwościowych (np. tarcia głowicy) oraz zakłóceń wysokoczęstotliwościowych.
2. **Ekstrakcja MFCC:** Z przefiltrowanego sygnału wyznaczono **20 współczynników cepstralnych w skali Mel (MFCC)**.
3. **Agregacja Statystyczna:** Ze względu na zmienność czasową sygnału w oknie 2-sekundowym, dla każdego z 20 współczynników obliczono średnią (*mean*) oraz odchylenie standardowe (*std*). Daje to łącznie **40 cech numerycznych** opisujących każdy segment.

Wynikowa Struktura Danych


W rezultacie prac powstała hierarchiczna struktura plików CSV zapewniająca pełną identyfikowalność danych:

- **Poziom 1 (Metadane):** `train.csv`, `val.csv`, `test.csv` – listy nagrań z pełnym opisem klinicznym.
- **Poziom 2 (Segmenty):** `*_segmented.csv` – indeksy 2-sekundowych wycinków audio (wsad dla CNN).
- **Poziom 3 (Cechy):** `features_*_segmented.csv` – wektory cech numerycznych MFCC (wsad dla k-NN).

A. Punkty osłuchiwania (Widoki akustyczne)

Kluczowy element określający miejsce przyłożenia stetoskopu:

- **Dla serca (Heart Sounds):**
 - **A** - Apex (Koniuszek serca)
 - **RUSB** - Right Upper Sternal Border (Prawy górny brzeg mostka)
 - **LUSB** - Left Upper Sternal Border (Lewy górny brzeg mostka)
 - **LLSB** - Left Lower Sternal Border (Lewy dolny brzeg mostka)
 - **RC / LC** - Right/Left generic locations (Prawa/Lewa strona)
- **Dla płuc (Lung Sounds):**
 - **RUA, RMA, RLA** - Prawe płuco (Right Upper/Middle/Lower Anterior)
 - **LUA, LMA, LLA** - Lewe płuco (Left Upper/Middle/Lower Anterior)




Rysunek 1. przedstawia schemat anatomiczny punktów przyłożenia stetoskopu na klatkę piersiową

https://www.researchgate.net/figure/Chest-zone-landmarks-for-recording-A-lung-sounds-and-B-heart-sounds-Apex-A_fig3_391390555

B. Typ zarejestrowanego zjawiska (Sound Type)


Nagrania przedstawiają konkretne stany fizjologiczne lub patologiczne:

- **Serce:** NH (Normal), AF (Atrial Fibrillation - Migotanie przedsionków), ESM (Ejection Systolic Murmur - Szmer wyrzutowy), S3, S4, T, AVB, LDM, MSM, LSM.
- **Płuca:** NL (Normal), W (Wheeze - Świsty), FC, R (Rhonchi - Furczenia), PR, CC.



C. Dane demograficzne (Gender)

- **F** - Kobieta (Female)
- **M** - Mężczyzna (Male)



Skanowanie i naprawa integralności zbioru danych

Ze względu na błędy w plikach źródłowych (białe znaki w nazwach, niespójna struktura folderów), w drugiej fazie opracowano skrypt skanujący strukturę dyskową. Mapowanie ścieżek: Skrypt przeskanował katalog, tworząc indeks plików *.wav. Dzięki temu proces przetwarzania stał się niezależny od błędnych ścieżek zapisanych w plikach CSV, co pozwoliło na odzyskanie i przetworzenie ponad 90% dostępnych nagrań.

Inne wykorzystanie danych

Dane zostały wykorzystane, przez zespół z McMaster University:


<https://github.com/Torabiy/HLS-CMDS>


Pozwala nam to na analizę naszej pracy i sprawdzenie czy idziemy w dobrym kierunku, a w dalszej fazie projektu na porównanie naszych wyników z innymi.

Analiza Widmowa (FFT i Spektrogramy)

Przeprowadzono analizę sygnałów w domenie częstotliwości. Kluczowe kroki obejmowały:

- **Szybka Transformacja Fouriera (FFT):** Wykonano analizę widma amplitudowego, co pozwoliło na wstępną identyfikację pasm dominujących i lokalizację szumu.






**Rysunki 1 i
2:
Porównanie
Widm**

Amplitudowych (FFT) dla klas Normal i Pathology

- **Spektrogramy** : Wygenerowano spektrogramy, które pokazały, jak rozkład energii w funkcji częstotliwości zmienia się w czasie. Umożliwiło to wstępną **analizę pasmową** i lokalizację chwilowych zjawisk diagnostycznych. Są one przedstawione poniżej:



Rysunek 1: Klasa "Normal" (Serce Zdrowe) Wykres przedstawia typową charakterystykę częstotliwościową dla zdrowych tonów serca (S1 i S2).



- **Koncentracja energii:** Dominująca część energii sygnału skupiona jest w **niskich częstotliwościach (poniżej 150-200 Hz)**.
- **Struktura:** Widoczne są wyraźne, odseparowane piki odpowiadające podstawowym składowym harmonicznym uderzeń serca.
- **Tło:** Powyżej 300 Hz amplituda sygnału gwałtownie spada, co wskazuje na brak istotnych szmerów lub zakłóceń patologicznych (tzw. "czyste widmo").


Rysunek 2: Klasa "Pathology" (Patologia) Wykres obrazuje sygnał obciążony stanem chorobowym (np. szmery, niedomykalność zastawek).

- **Poszerzenie pasma (Broadband):** Obserwuje się znaczący "wyciek" energii do **wyższych częstotliwości (powyżej 400-600 Hz)**. Jest to cecha charakterystyczna dla przepływów turbulentnych krwi lub zjawisk akustycznych w płucach (trzeszczenia).
- **Charakter szumowy:** Widmo jest bardziej płaskie i nieregularne ("poszarpane"), przypominające charakterystykę szumu różowego lub białego, co zaciera wyraźną strukturę tonów podstawowych widoczną u pacjenta zdrowego.

Wniosek z porównania: Różnice w rozkładzie gęstości widmowej mocy (PSD) między Rysunkiem 1 a 2 potwierdzają, że informacja diagnostyczna jest zakodowana nie tylko w czasie, ale przede wszystkim w **częstotliwości**. Uzasadnia to transformację sygnałów 1D do postaci reprezentacji czasowo-częstotliwościowych (spektrogramy), które stanowią wsad dla modelu sieci neuronowej.

Skalogramy i analiza falkowa





Przeprowadzona analiza falkowa pozwoliła na wyodrębnienie istotnych cech diagnostycznych. Dla sygnałów serca dominująca energia skupia się w poziomie aproksymacji **cA5** (zakres niskich częstotliwości, <60 Hz), co odpowiada tonom S1/S2. Z kolei dla sygnałów płucnych istotna energia obserwowana jest w poziomach detali **cD1** i **cD2** (zakres >500 Hz), co jest charakterystyczne dla szumu przepływu powietrza. Potwierdza to, że cechy falkowe (MAV - Mean Absolute Value z poszczególnych poziomów) są skutecznymi predyktorami dla modelu klasyfikującego. Ponadto, analiza skalogramów (CWT z falką Morleta) umożliwiła wizualizację patologii jako zaburzeń wzorca czasowo-częstotliwościowego – takich jak dodatkowe składowe wysokoczęstotliwościowe w przypadku trzeszczeń płucnych oraz wypełnienie okien ciszy w przypadku szmerów sercowych.

Analiza falkowa bardziej nam się przyda przy dostarczaniu danych liczbowych dla modelu, ponieważ dostarcza nam szczegółowych danych liczbowych które są łatwiejsze do prowadzenia analizy i obróbki niż pliki dźwiękowe, dzięki czemu jest to lepsza metoda niż FFT.

Filtrowanie i Optymalizacja Sygnału

Zastosowaliśmy filtr pasmowoprzepustowy Butterwortha 100 Hz - 1500 Hz, ale okazało się, że dane zostały już wcześniej odfiltrowane i odszumione, więc nie było sensu filtrować danych, żeby nie utracić wartościowych informacji. W niektórych przypadkach wystarczyła nam część pliku audio, na przykład w skalogramach w analizie falkowej, ponieważ wyniki i tak by nam się powtarzały.

Podsumowanie

Przeprowadzona analiza eksploracyjna oraz wstępne przetwarzanie sygnałów ze zbioru HLS-CMDS pozwoliły na zidentyfikowanie kluczowych wyzwań oraz wytyczenie ścieżki dla budowy modeli klasyfikacyjnych.

1. Wyzwanie niebalansowanych danych (Class Imbalance) Głównym problemem projektowym jest znaczna dysproporcja klas: aż 85,9% próbek to nagrania patologiczne, a jedynie 14,1% to nagrania pacjentów zdrowych. Trenowanie modelu na tak rozłożonym zbiorze niesie wysokie ryzyko **przeuczenia (overfitting)** w kierunku klasy dominującej (model będzie miał tendencję do diagnozowania każdego przypadku jako patologii).

- **Wnioski:** Konieczne jest zastosowanie technik równoważenia zbioru. Oprócz prostej duplikacji (oversampling), planujemy wdrożyć zaawansowaną **augmentację danych** (np. dodawanie szumu białego, delikatne przesunięcia czasowe, modyfikację pitchu) dla klasy "Normal", aby sztucznie zwiększyć jej liczebność bez utraty generalizacji. Kwestia ta pozostaje otwarta do dalszej dyskusji i testów.

2. Przewaga Analizy Falkowej nad FFT w ekstrakcji cech Porównanie metod analizy widmowej (FFT/Spektrogramy) z analizą czasowo-częstotliwościową (Falki) wykazało, że ta druga jest bardziej użyteczna dla celów uczenia maszynowego w tym projekcie.

- Choć FFT świetnie wizualizuje ogólny charakter szumu (szerokopasmowy szum w patologii vs harmoniczne piki w zdrowym sercu), to traci informację o umiejscowieniu zjawiska w czasie.
- Analiza falkowa (Wavelet Analysis) pozwoliła na wyodrębnienie konkretnych parametrów liczbowych (np. energia na poziomie aproksymacji cA5 dla serca lub detali cD1/cD2 dla płuc).
- **Decyzja:** Wartości z analizy falkowej posłużą jako **bezpośredni wektor cech (feature vector)** dla klasyfikatorów. Pozwoli to na znaczną redukcję wymiarowości danych i uniknięcie pracy na surowych, obliczeniowo ciężkich plikach audio, co przyspieszy proces trenowania.

3. Jakość danych i anonimizacja Analiza wykazała, że sygnały są już wstępnie odfiltrowane, co pozwoliło na rezygnację z planowanego filtra Butterwortha (100-1500 Hz), aby uniknąć utraty istotnych informacji diagnostycznych. Istotnym ograniczeniem zbioru jest brak identyfikatorów pacjentów (brak pewności, czy różne nagrania nie pochodzą od tej samej osoby). Uniemożliwia to grupowanie nagrań "per pacjent", co mogłoby poprawić wiarygodność walidacji krzyżowej, jednak w kontekście samej detekcji cech patologicznych (a nie identyfikacji osób) dane pozostają użyteczne.

4. Planowane modele i dalsze kroki W kolejnym etapie projektu skupimy się na implementacji i porównaniu trzech podejść modelowania:

1. **Klasyczne Uczenie Maszynowe:** Algorytm k-Najbliższych Sąsiadów (k-NN) jako model bazowy (baseline) operujący na cechach falkowych.
2. **Sieci Neuronowe (ANN/CNN):** Własna architektura sieci dedykowana do klasyfikacji binarnej (Zdrowy/Patologia).
3. **Transfer Learning:** Wykorzystanie gotowych, pretrenowanych modeli do przetwarzania dźwięku (np. architektury typu Audio Transformers lub modele trenowane na muzyce/mowie), dostrojonych (fine-tuning) do specyfiki dźwięków medycznych.

Podział zadań w zespole

Osoba	Przypisane Zadania (ID)
[FraneK]	Podział danych, statystyka klas, przygotowanie danych, wizualizacja podstawowa
[Maciek]	Filtry, Analiza pasmowa, analiza częstotliwościowa, wizualizacja Spektrogramów

[Karol]

Analiza Falkowa, odszumianie, wizualizacja skalogramów, research gotowych rozwiązań

STAR WARS

CZEŚĆ II
ATAK KLONÓW

Segmentacja sygnału: Sliding Window

W procesie przygotowania danych medycznych (dźwięki serca i płuc), kluczowym etapem była segmentacja surowych nagrań przy użyciu techniki **Sliding Window** (przesuwne okna). Metoda ta polega na pocięciu długiego nagrania na fragmenty o stałej długości, co pozwala na ujednolicenie danych wejściowych dla modelu klasyfikacyjnego.

Pozwoliło to:

1. **Ujednolicić długości próbek:** Surowe nagrania medyczne mają różny czas trwania (od kilku do kilkudziesięciu sekund). Drzewa decyzyjne i inne modele ML wymagają wektora cech o stałym rozmiarze. Segmentacja na 2-sekundowe fragmenty pozwala na ekstrakcję cech z obszarów o identycznym czasie trwania.
2. **Zbalansować zbiór danych (Data Augmentation):** W pierwotnym zbiorze zidentyfikowano 85% przypadków patologicznych. Aby uniknąć biasu modelu (tendencji do ignorowania klasy Normal), zastosowaliśmy Sliding Window z różnym krokiem (**stride**) dla poszczególnych klas:
 - **Klasa Normal:** Zastosowano okno 2.0s z krokiem **0.5s**. Dzięki temu okna nakładają się na siebie (overlap 75%), co pozwala na stworzenie wielu próbek z jednego nagrania zdrowego pacjenta.
 - **Klasa Pathology:** Zastosowano okno 2.0s z krokiem **2.0s**. Fragmenty nie nachodzą na siebie, co ogranicza liczbę próbek patologicznych w stosunku do zdrowych.
3. **Zwiększyć rozdzielczość lokalną:** Krótkie okno (2.0s) pozwala modelowi skupić się na konkretnych cyklach pracy serca lub fazach oddechowych, zamiast uśredniać cechy z całego, długiego nagrania, gdzie patologia mogłaby zostać zagłuszona przez momenty ciszy.

Parametry techniczne procesu:

- **Długość okna:** 2.0 sekundy.
- **Krok (Normal):** 0.5 sekundy (multiplikacja danych).
- **Krok (Pathology):** 2.0 sekundy (brak zakładki).

Ekstrakcja cech psychoakustycznych (MFCC)

Dla potrzeb klasyfikacji klasycznej (SVM) dokonano parametryzacji sygnału. **Współczynniki MFCC:** Z każdego przefiltrowanego nagrania wyekstrahowano 20 współczynników MFCC. Dane te zagregowano do postaci wektora cech, obliczając średnią oraz odchylenie standardowe dla każdego współczynnika.

Wynik: Utworzenie plików features_train.csv oraz features_test.csv, zawierających 40 kolumn z cechami numerycznymi dla każdego pacjenta.

Optymalizacja hiperparametrów metodą Grid Search

W celu uzyskania najwyższej skuteczności modelu SVM, przeprowadzono proces automatycznego strojenia parametrów.


GridSearchCV: Przeszukano przestrzeń parametrów dla jądra RBF oraz Poly, testując różne wartości współczynnika C (kara za błędy) oraz gamma. Algorytm wyłonił optymalną konfigurację: kernel: 'rbf', C: 10, gamma: 'scale'.


Ewaluacja modelu i Macierz Pomyłek

Ostatnim etapem była ocena jakości modelu na zbiorze testowym

Skuteczność: Model uzyskał **Accuracy na poziomie 95.65%**.

Analiza błędów: Wygenerowano macierz pomyłek, która wykazała, że model bezbłędnie identyfikuje przypadki patologiczne (Recall 1.00), natomiast posiada trudności z poprawną klasyfikacją nielicznych próbek zdrowych w zbiorze testowym (tzw. problem niezbalansowanego zbioru).





Drzewo Decyzyjne

Charakterystyka modelu Jako punkt odniesienia (baseline) dla zaawansowanych sieci neuronowych i modeli SVM, zaimplementowano model oparty na Drzewie Decyzyjnym (Decision Tree Classifier). Wybór tego modelu podyktowany był jego pełną interpretowalnością - pozwala on prześledzić każdą decyzję modelu na podstawie konkretnych progów częstotliwości.

Ekstrakcja Cech (Feature Engineering) Zamiast karmić model surowym dźwiękiem, zastosowano zaawansowaną ekstrakcję cech w dziedzinie częstotliwości:

MFCC (Mel-frequency cepstral coefficients): Wyznaczono 20 współczynników MFCC, które najlepiej oddają sposób, w jaki ludzkie ucho odbiera dźwięki stetoskopowe.

Statystyki opisowe: Aby uniknąć nadmiernego uśrednienia (co gubiło rytm serca), dla każdego segmentu wyliczono: średnią, odchylenie standardowe, wartości minimalne oraz maksymalne z MFCC. Dało to łącznie 80 cech opisujących każdą próbkę dźwięku.

Konfiguracja i tuning modelu:



Użyto parametru `class_weight='balanced'`, aby dodatkowo zabezpieczyć model przed faworyzowaniem patologii.

Głębokość drzewa została ograniczona (`max_depth=12-15`), aby zapobiec „wyuczeniu się próbek na pamięć” (overfitting) przy zachowaniu zdolności do rozróżniania szybkich uderzeń serca.

Wnioski z modelu bazowego: Model Drzewa Decyzyjnego osiągnął 72% dokładności dla płuc (LS) oraz 59% dla serca (HS).

Bezpieczeństwo diagnostyczne: Model wykazuje bardzo wysoki Recall dla patologii (0.79 - 0.83). Oznacza to, że model jest „wyczulony” na chorobę i skutecznie minimalizuje ryzyko wypisania chorego pacjenta do domu jako zdrowego.

Rola Baseline: Niższa precyzja w porównaniu do modeli CNN i SVM wskazuje, że proste progi decyzyjne to za mało, aby w pełni opisać złożoność szmerów serca.



Model cnn

Używamy modelu ResNet (Mel-spectrogram) na podstawie tekstu MS-SincResNet: Joint learning of 1D and 2D kernels using multi-scale SincNet and ResNet for music genre classification

Zastosowano konwolucyjną sieć neuronową (CNN) do klasyfikacji Mel-spektrogramów (obrazy PNG). Dane pobierano z katalogów podzielonych na klasy {HS, LS}/{0, 1} przy użyciu indeksów CSV.

W ramach przygotowania danych (tf.data) obrazy **przeskalowano do 256 :256**, znormalizowano (Rescaling 1./255) i podzielono na wsady (batch size: 32).

Architektura modelu:

Sieć składa się z dwóch bloków ekstrakcji cech (Conv2D 16 filtrów → MaxPool oraz Conv2D 32 filtry → MaxPool) oraz klasyfikatora gęstego: Flatten → Dense(1024) → Dropout(0.1) → Dense(64) → Dense(1) z aktywacją **sigmoid**.

Model trenowano z użyciem optymalizatora **Adam** i funkcji straty **binary_crossentropy**. Eksperyment przeprowadzono w dwóch osobnych pętlach dla modalności serca (HS) i płuc (LS), aby porównać skuteczność klasyfikacji dla różnych źródeł sygnału.

Trening HS:


Epoka	Strata treningowa (Loss)	Dokładność treningowa (Accuracy)	Strata walidacyjna (Val Loss)	Dokładność walidacyjna (Val Accuracy)
1	2.2191	59.89%	0.6226	59.50%
2	0.5116	74.21%	0.5021	79.34%
3	0.3597	83.22%	0.2943	88.02%

4	0.2649	89.07%	0.1842	90.91%
5	0.2131	90.76%	0.2425	90.08%
6	0.0783	96.92%	0.0974	96.28%
7	0.0333	99.15%	0.1939	92.15%
8	0.0221	99.38%	0.1550	95.87%
9	0.0093	99.85%	0.1603	95.87%
10	0.0046	99.92%	0.1438	95.45%

Wyniki treningu (HS): Proces uczenia trwał 10 epok. Model osiągnął stabilizację już w okolicach 6. epoki.

- **Najlepsza dokładność walidacyjna:** 96.28% (Epoka 6)
- **Końcowa strata walidacyjna:** 0.1438
- **Wynik na zbiorze testowym (Test Accuracy):** 99.24%

Można także zauważyć, że już po 6 epoce doszło do przetrenowania i mimo tego, że zwiększał się wynik na zbiorze walidacyjnym zaczął pogarszać się




Trening LS:

Epoka	Strata treningowa (Loss)	Dokładność treningowa (Accuracy)	Strata walidacyjna (Val Loss)	Dokładność walidacyjna (Val Accuracy)
1	2.3676	61.50%	0.5501	77.69%
2	0.4561	78.90%	0.2481	95.38%
3	0.2695	89.26%	0.0918	99.23%
4	0.1573	94.25%	0.0732	98.46%
5	0.1245	95.92%	0.0675	99.23%
6	0.0606	98.03%	0.5125	80.00%
7	0.0402	99.09%	0.0234	99.23%
8	0.0038	100.00%	0.0396	97.69%
9	0.0015	100.00%	0.0355	99.23%
10	0.0008	100.00%	0.0355	99.23%

Wyniki treningu (LS): Model osiągnął pełną zbieżność (100% dokładności na zbiorze treningowym) w 8. epoce. Widoczna jest wysoka skuteczność na zbiorze walidacyjnym, choć wynik na zbiorze testowym sugeruje nieznaczną różnicę w generalizacji względem treningu.

- **Najlepsza dokładność walidacyjna:** 99.23% (osiągnięta m.in. w epoce 3, 5, 7, 9 i 10)
- **Końcowa strata walidacyjna:** 0.0355
- **Wynik na zbiorze testowym (Test Accuracy):** 89.14%



Wnioski:

Przeprowadzone eksperymenty potwierdziły wysoką skuteczność zastosowania Konwolucyjnych Sieci Neuronowych (CNN) w analizie obrazowej reprezentacji dźwięku (Mel-spektrogramów).

1. Wysoka skuteczność klasyfikacji dźwięków serca (HS) Model dedykowany dla serca osiągnął wybitne wyniki, notując dokładność na zbiorze testowym na poziomie **99.24%**.

- Krzywe uczenia (Tabela 1) wykazują stabilny spadek funkcji straty i wzrost dokładności zarówno na zbiorze treningowym, jak i walidacyjnym.
- Niewielka różnica między wynikami walidacji a testu świadczy o doskonałej zdolności modelu do **generalizacji** (brak oznak przeuczenia). Sugeruje to, że cechy patologiczne w sygnale serca (np. szmery, dodatkowe tony) są bardzo wyraźnie widoczne na spektrogramach i łatwe do wyekstrahowania przez filtry konwolucyjne.

2. Zjawisko przeuczenia w klasyfikacji dźwięków płuc (LS) W przypadku modelu płucnego zaobserwowano istotną dysproporcję między wynikami treningowymi a testowymi.

- Model osiągnął **100% dokładności** na zbiorze treningowym już w 8. epoce (Tabela 2), jednak wynik na zbiorze testowym wyniósł **89.14%**.

- Ta różnica (ok. 11 punktów procentowych) wskazuje na występowanie zjawiska **przeuczenia (overfitting)**. Model "nauczył się na pamięć" szumu lub specyficznych artefaktów ze zbioru treningowego, co utrudniło mu poprawną klasyfikację nowych, nieznanych próbek testowych. Może to wynikać z większej złożoności i zmienności dźwięków płucnych (np. różne rodzaje świstów i trzeszczeń) w porównaniu do bardziej rytmicznych dźwięków serca.

3. Ocena metodyki (Audio-to-Image) Transformacja sygnałów 1D do postaci obrazów 2D (spektrogramy) okazała się słusznym podejściem. Wysokie wyniki (szczególnie dla HS) dowodzą, że kluczowe informacje diagnostyczne są zawarte w strukturze czasowo-częstotliwościowej, którą sieci CNN potrafią skutecznie interpretować.

Klasyfikacja klasyczna: Algorytm k-Najbliższych Sąsiadów (k-NN)

Jako punkt odniesienia (baseline) dla zaawansowanych sieci neuronowych, zastosowano klasyczny algorytm uczenia maszynowego – k-Najbliższych Sąsiadów (k-NN). Podejście to opiera się na analizie numerycznych wektorów cech wyekstrahowanych z sygnału (wartości statystyczne z analizy falkowej/czasowej), a nie na surowych obrazach.

Metodyka i Implementacja

Zaimplementowano własną klasę `MojKNN` wykorzystującą metrykę euklidesową do obliczania odległości między próbkami. Klasyfikacja odbywa się na zasadzie głosowania większościowego k najbliższych sąsiadów ze zbioru treningowego.

W celu weryfikacji poprawności implementacji, wyniki własnego algorytmu porównano z referencyjną implementacją z biblioteki `scikit-learn`.

Preprocessing i Dobór Hiperparametrów

- **Standaryzacja:** Ze względu na naturę algorytmu k-NN (wrażliwość na skalę danych), wszystkie cechy wejściowe zostały poddane standaryzacji (`StandardScaler`) – odjęcie średniej i podzielenie przez odchylenie standardowe.
- **Optymalizacja k:** Przeprowadzono procedurę doboru optymalnej liczby sąsiadów k. Przetestowano wartości nieparzyste z zakresu od 1 do 51. Wybór najlepszego k nastąpił na podstawie dokładności (accuracy) na wydzielonym zbiorze walidacyjnym.
- **Trening finalny:** Ostateczny model dla wybranego k został przetrenowany na połączonym zbiorze treningowym i walidacyjnym, a następnie oceniony na niezależnym zbiorze testowym.

Ewaluacja modelu k-NN – Wyniki

Poniżej przedstawiono wyniki klasyfikacji osobno dla modalności serca (HS) i płuc (LS).


Wyniki dla Serca (HS)

Na podstawie walidacji wybrano optymalną liczbę sąsiadów: **k = 1**

- **Dokładność (Test Accuracy): 92%**
- **Zgodność implementacji własnej z biblioteczną: 100%**

Macierz pomyłek i Raport klasyfikacji

Poniższa macierz prezentuje skuteczność rozróżniania pacjentów zdrowych od patologicznych przy użyciu wyselekcjonowanych cech liczbowych.




Rysunek Z. Macierz pomyłek dla algorytmu k-NN (HS).

Wyniki dla Płuc (LS)

Na podstawie walidacji wybrano optymalną liczbę sąsiadów: **k = 25**.

- **Dokładność (Test Accuracy): 95%**
- **Zgodność implementacji własnej z biblioteczną: 100%**

Macierz pomyłek i Raport klasyfikacji



CZEGO NIE UDAŁO SIĘ ZAIMPLEMENTOWAĆ POPRAWNIE

Słabość Klasyfikacji LS (Płuca) w Drzewie Decyzyjnym

Patrząc na nasze wyniki:

Wynik: Dla LS precyzja dla klasy Pathology to tylko **0.35**.

Wniosek: Model bardzo często myli się, przypisując zdrowym pacjentom patologię płuc. Drzewo Decyzyjne okazało się zbyt prostym modelem dla tak złożonego sygnału jak szmery płucne (które mają niższe częstotliwości i są bardziej rozmyte niż uderzenia serca).

PORÓWNANIE MODELI

Porównanie wyników dla Dźwięków Serca (HS)

Dźwięki serca okazały się łatwiejsze do klasyfikacji dla większości modeli, co wynika z ich bardziej rytmicznej i przewidywalnej natury.

Model	Accuracy	Precision (Normal/Pathology)	Recall (Normal/Pathology)
2D CNN (Karol)	99,24%	0,96 / 1,00	1,00 / 0,99

SVM (Maciek)	98,00%	0,93 / 1,00	0,98 / 0,98
k-NN (Benchmark)	87,73%*	0,91 / 0,84	0,85 / 0,91
Drzewo Decyzyjne	59,00%	0,76 / 0,52	0,41 / 0,83

Porównanie wyników dla Dźwięków Płuc (LS)

Dźwięki płuc stanowią większe wyzwanie diagnostyczne. Modele wykazują tutaj niższą precyzję w wykrywaniu patologii, co sugeruje, że szmery płucne są trudniejsze do odróżnienia od tła.

Model	Accuracy	Precision (Normal/Pathology)	Recall (Normal/Pathology)
2D CNN (Karol)	89,14%	0,99 / 0,76	0,84 / 0,99
SVM (Maciek)	84,00%	0,99 / 0,68	0,76 / 0,99
Drzewo Decyzyjne	72,00%	0,94 / 0,35	0,70 / 0,79

Aby rzetelnie ocenić model medyczny, nie wystarczyło podać tylko ogólnej skuteczności. Użyliśmy następujących metryk:

Accuracy (Dokładność): Procent wszystkich poprawnych predykcji (zarówno zdrowych, jak i chorych) w stosunku do całości zbioru.

Precision (Precyzja): Odpowiada na pytanie: "Jeśli model przewidział patologię, jakie jest prawdopodobieństwo, że pacjent faktycznie jest chory?".

Recall (Czułość): Odpowiada na pytanie: "Jaki procent wszystkich chorych osób model zdołał poprawnie wykryć?".

F1-Score: Średnia harmoniczna między precyzją a czułością. Daje ogólny obraz jakości modelu, szczególnie gdy grupy (zdrowi/chorzy) nie są równe liczebnie.

Support: Liczba rzeczywistych wystąpień danej klasy w testowanym zbiorze danych.

Analiza porównawcza wyników jednoznacznie wskazuje na przewagę sieci konwolucyjnych (2D CNN) nad klasycznymi metodami uczenia maszynowego w

zadaniu diagnostyki akustycznej. Dominacja modelu CNN (z dokładnością sięgającą 99% dla serca) wynika z jego unikalnej zdolności do analizy spektrogramów jako obrazów, co pozwala na automatyczne wykrywanie złożonych relacji czasowo-częstotliwościowych, które są tracone przy redukcji sygnału do prostych cech liczbowych. Algorytm SVM uplasował się jako solidna alternatywa, skutecznie separując klasy w przestrzeni wielowymiarowej (MFCC), jednak ustępował sieciom neuronowym przy bardziej złożonych, niestacjonarnych szmerach płucnych. Z kolei najstabsze wyniki Drzewa Decyzyjnego dowodzą, że proste, sztywne reguły warunkowe są niewystarczające do modelowania nieliniowej natury sygnałów biomedycznych, co prowadzi do istotnych błędów diagnostycznych i problemów z generalizacją wiedzy.

Członek Zespołu	Obszar / Kategoria	Przypisane Zadania i Odpowiedzialność
Franek	Inżynieria Danych	Implementacja techniki <i>Sliding Window</i> (segmentacja z nakładaniem) w celu naprawy balansu klas.
	Modelowanie	Implementacja, trening i walidacja modelu Drzewa Decyzyjnego (<i>Decision Tree</i>).
	Dokumentacja	Redakcja i korekta wcześniejszych części raportu zgodnie z uwagami prowadzącego.
Maciek	Przetwarzanie Danych	Generowanie spektrogramów i zapis do plików graficznych (przygotowanie wsadu dla CNN).
	Modelowanie	Eksperymenty z modelami: Maszyna Wektorów Nośnych (SVM) oraz Sieci Grafowe (GNN).
	Analiza	Weryfikacja poprawności potoku przetwarzania wstępnego (<i>Preprocessing Verification</i>).
Karol	Modelowanie	Budowa i trening sieci 2D CNN (na spektrogramach) oraz modelu k-NN (jako <i>benchmark</i>).
	Nadzór Techniczny	Weryfikacja poprawności kodu (<i>Code Review</i>) oraz wsparcie przy rozwiązywaniu błędów.
	Łączenie kodu	Połączenie kodu ze sobą, zunifikowanie przetwarzania danych.

